

Hướng dẫn sử dụng Metadata trong RAG Pipeline

Corpus: VinFast EV — 1,488 chunks / 308 tài liệu (tiếng Việt)

Cập nhật: 2026-06-17

Metadata có những trường gì?

Metadata chia thành 2 nhóm: [P] trích xuất tự động khi parse, [L] do LLM generate lúc ingestion.

Nhóm [P] — Rule-based, luôn có

Trường	Ý nghĩa
chunk_id	ID duy nhất của chunk
document_id	ID tài liệu gốc
source_url	URL nguồn
source_type	Loại nguồn (url)
language	Ngôn ngữ (vi)
document_type	Loại tài liệu (rule-based)
chunk_index	Vị trí chunk trong tài liệu
total_chunks	Tổng số chunk của tài liệu
char_count	Số ký tự

Nhóm [L] — LLM-extracted, cần cấu hình INGESTION_LLM_*

Trường	Ý nghĩa
summary	Tóm tắt nội dung chunk (1–2 câu)
keywords	Danh sách từ khóa (~8/chunk)
questions	Câu hỏi mà chunk có thể trả lời (~4/chunk)
entities	Thực thể có tên: xe, địa điểm, thương hiệu (~3/chunk)
document_type	Loại tài liệu (LLM classify, chính xác hơn [P])
language	Ngôn ngữ (LLM detect)

Trường nào dùng được, ở đâu, làm gì?

[OK] entities — Pre-filter trong Qdrant

Dùng khi: Query của user nhắc đến tên xe hoặc địa điểm cụ thể.

Cách hoạt động:

Query: "pin VF 8 bao nhiêu kWh?"
→ extract entity: "VF 8"
→ Qdrant filter: entities CONTAINS "VF 8"

→ search chỉ trong ~175 chunk thay vì 1,488 chunk

Lưu ý quan trọng: LLM không nhất quán khi viết tên xe — cần normalize trước khi filter:

"VF 8" | "VinFast VF 8" | "VF8" | "VF 8 Plus" → đều cần về "VF 8"

Entities đáng tin cậy để filter: tên model VF (VF 3–9, VF e34), tên dòng xe máy điện (Theon S, Klara S...), thành phố (Hà Nội, Đà Nẵng...).

Không nên filter: "VinFast" (75% chunk — quá rộng), entities chỉ xuất hiện 1–2 lần.

[OK] questions — Q→Q Retrieval (hiệu quả nhất)

Vấn đề cần giải quyết: Query của user (ngắn, thông dụng) rất khác chunk text (dài, kỹ thuật) → similarity thấp, lấy nhầm chunk.

Giải pháp Q→Q:

Thay vì: `embed(query)` → so sánh với `embed(chunk_text)` ← semantic gap lớn

Dùng: `embed(query)` → so sánh với `embed(question)` ← cùng dạng câu hỏi

↓
lấy `chunk_id` của question đó

Cách setup:

1. Lấy toàn bộ ~5,800 câu hỏi từ tất cả chunks
2. Embed từng câu hỏi → lưu vào Qdrant collection questions (payload gồm `chunk_id`)
3. Khi có query: search collection questions → lấy top `chunk_ids` → retrieve chunks đó

Ví dụ thực tế:

Query: "VF 8 đầy bình chạy được bao xa?"

Question: "VF 8 chạy được bao nhiêu km một lần sạc?" ← match cao
→ chunk về quãng đường VF 8 được trả về đúng

[OK] keywords — BM25 Augmentation (offline)

Dùng khi: Index vào sparse retrieval (BM25) để tăng recall từ khóa.

Cách hoạt động:

Chunk text gốc: "Hệ thống Immobilizer ngăn chặn việc khởi động trái phép..."

Keywords LLM: ["chống trộm", "chìa khóa", "bảo vệ", "khởi động"]

→ Nối keywords vào text trước khi index BM25:

"...khởi động trái phép... chống trộm chìa khóa bảo vệ"

Query: "VF e34 có chống trộm không?"

→ BM25 match được "chống trộm" dù chunk text không dùng từ đó

Lưu ý: Keywords chủ yếu là synonym / từ thông dụng hơn so với chunk text. Không dùng keywords để filter — quá generic.

[OK] document_type — Boost khi Re-rank

Dùng khi: Re-rank kết quả retrieval dựa vào loại tài liệu phù hợp với intent của query.

Loại query	document_type ưu tiên
"thông số kỹ thuật...", "dung lượng pin...", "công suất..."	spec_sheet
"làm thế nào...", "hướng dẫn...", "cách..."	faq, manual
"chính sách...", "điều khoản...", "bảo hành..."	policy
Tin tức, tổng quan	article

[OK] summary — Re-rank & Hiển thị

2 cách dùng:

1. Re-rank rẻ hơn: So sánh query với summary (~100 ký tự) thay vì full chunk (~800 ký tự) → tiết kiệm token 8x khi gọi LLM re-ranker.
2. Hiển thị snippet: Dùng summary làm đoạn mô tả ngắn trong UI kết quả, thay vì cắt thô chunk text.

[OK] chunk_index + total_chunks — Context Expansion

Dùng khi: Chunk tìm được nằm giữa tài liệu và nội dung bị cắt đứt → lấy thêm chunk liền kề để có context đầy đủ hơn.

```
chunk_index=2, total_chunks=6  
→ có thể lấy thêm chunk_index=1 và chunk_index=3 để mở rộng context
```

[OK] source_url — Citation

Hiển thị URL nguồn trong câu trả lời để user có thể kiểm chứng. Không dùng để filter (toàn bộ đều là vinfastauto.com).

[X] language, source_type — Không dùng được

- language: 100% vi → không phân biệt được gì
- source_type: 100% url → không phân biệt được gì

Tóm tắt — Bảng tổng hợp

Metadata	Dùng ở giai đoạn	Làm gì	Ưu tiên
questions [L]	Retrieval (online)	Q→Q collection riêng trong Qdrant	[Cao] Cao nhất

Metadata	Dùng ở giai đoạn	Làm gì	Ưu tiên
entities [L]	Query processing (online)	Pre-filter Qdrant theo model/địa điểm	[Cao] Cao
keywords [L]	Index (offline, 1 lần)	Nối vào text để tăng BM25 recall	[TB] Trung bình
document_type [L]	Re-ranking (online)	Boost score theo loại tài liệu	[TB] Trung bình
summary [L]	Re-ranking / UI (online)	Re-rank rẻ hơn, hiển thị snippet	[TB] Trung bình
chunk_index [P]	Post-retrieval (online)	Mở rộng context lấy chunk liền kề	[Nho] Nhỏ
source_url [P]	Response (online)	Hiển thị citation cho user	[Nho] Nhỏ
language [P/L]	—	Không dùng	[X]
source_type [P]	—	Không dùng	[X]

Pipeline đề xuất

